

CM-LLM

Cognitive Memory-Augmented Large Language Models

Technical Specification — Draft Open Contribution

Abstract

Large Language Models suffer from three correlated structural limitations: they are stateless (each session starts from scratch), prone to confabulation (they generate plausible but ungrounded statements), and treat all information with equal weight regardless of its age and type. We propose CM-LLM, an architecture that addresses all three limitations not by modifying the underlying transformer, but by encapsulating it within a structured cognitive-memory system.

The central claim is that confabulation is structurally impossible within working memory—not through post-hoc filtering, but by ontological construction.

Every node in active memory carries an explicit anchor to a real source; without such an anchor, it cannot exist there. Knowledge is neither filtered after entering memory nor admitted without being grounded.

A further benefit is a claim-type-specific decay mechanism, which is necessary for managing knowledge obsolescence and functions as an automatic form of epistemic hygiene. Superficial, noisy, or unreinforced content that are typically extracted from low-quality sources decays and disappears from working memory without manual intervention. The system naturally tends to retain information that has been repeatedly confirmed by different sources and forget the rest.

1. The Problem CM-LLM Solves

1.1 Three Limitations, One Common Root

Modern LLMs are fundamentally statistical-compression machines trained once and then frozen. This is both their strength generalization and their structural limitation:

Statelessness: every query starts from scratch. The model does not remember what it said yesterday, nor that the market data it is citing was accurate in 2022 but is no longer accurate today.

Confabulation: the model does not internally distinguish between “I read this in a reliable source” and “this seems plausible to me.” As a result, it presents both with the same degree of confidence.

Uniform weighting: a peer-reviewed scientific article and a post on X have the same weight once they enter the context. There is no concept of decay: information does not lose relevance over time.

These three limitations share a common root: the transformer has no internal representation of the epistemic status of knowledge. It knows what it knows, but it does not know how much it can be relied upon, where it came from, or how long it remains valid.

1.2 Decay as Hygiene, Not Merely Chronology

One non-obvious consequence of **differential decay** is that content extracted from low-quality sources—social media, aggregator websites, and substance-free content—has no mechanism for reinforcement. A viral story on X is not cited in scientific papers, does not appear in technical documents, and does not connect to other validated nodes. Without reinforcement, it decays.

By contrast, a mathematical definition is cited whenever the corresponding concept is used: it receives constant reinforcement and remains available.

The system does not need to manually distinguish between a “good source” and a “bad source.” It does so implicitly: the knowledge that survives is the knowledge confirmed by multiple directions over time. Noise eliminates itself.

2. Architecture: Five Mechanisms, One System

CM-LLM does not introduce new machine-learning models. It uses existing technologies—such as embeddings, linear algebra, and clustering—assembled so that their properties reinforce one another. The five mechanisms are different views of the same object, not separate modules.

2.1 Distributional Embeddings: Uncertainty in the Geometry

Each concept is represented not as a fixed point in semantic space, but as a Gaussian distribution:

$$\text{concept} \rightarrow \mathcal{N}(\mu, \Sigma) \text{ where } \mu \in \mathbb{R}^d, \Sigma \in \mathbb{R}^{d \times d}$$

μ is the center of the distribution—the prototypical meaning. Σ is the covariance—the semantic uncertainty. Confidence is the concentration of the distribution:

$$\text{confidence} = \frac{1}{\sqrt{\det(\Sigma)}}$$

Small Σ means a concentrated distribution and high confidence. Large Σ means a diffuse distribution and uncertainty.

The advantage over a fixed-point representation is that uncertainty is encoded directly in the geometry rather than as a separate metadata field.

Two concepts may be “close” and diffuse—an uncertain proximity—or close and concentrated—a robust proximity. A point embedding cannot make this distinction.

2.2 Claim-Type-Specific Decay: The Metric Deforms Over Time

Decay is not a fixed timer (TTL). It is a geometric deformation of the space: without reinforcement, the distribution associated with a concept expands and becomes less precise. The concept does not disappear but becomes increasingly uncertain until it is archived.

The decay coefficient α depends on the type of claim, not on the source:

Claim type	α (decay/day)	Half-life
Market data, prices, news	0.10	≈ 1 week
Opinions, interpretations, analyses	0.05	≈ 3 months
Established scientific facts	0.001	≈ 5 years
Mathematical definitions	0.0001	≈ 50 years

The covariance-update formula at each time step Δt is:

$$\Sigma(t + \Delta t) = \Sigma(t) + \alpha^T \cdot \Delta t \cdot I^d$$

Confidence decays exponentially:

$$\text{confidence}(t) \propto e^{-\lambda^T t}$$

When it falls below the 0.1 threshold, the node is moved to cold storage.

2.3 Cauchy-Inspired Stability Criterion: When Is a Representation “Mature”?

An idea is mature when the way the model represents it no longer changes as it processes successive layers. Formally, we measure how much the representation of a concept converges across the LLM’s layers.

For a sequence of representations $h_1, h_2, \dots, h_L$ across L layers:

$$\text{stability}(h_{1:L}) = \frac{1}{\binom{L}{2}} \sum_{i < j} \exp\left(-\frac{\|h_i - h_j\|^2}{2\sigma^2}\right)$$

Stability close to 1 means that the sequence is nearly Cauchy—all embeddings are close to one another—and the representation is mature. Stability close to 0 means that the representation is unstable: the concept has not yet “settled” across the model’s layers.

This signal serves two purposes:

- As an admission criterion for active memory: only stable representations are admitted.
- As an early-stopping mechanism during inference: if stability exceeds a threshold before the final layer, inference can stop early.

Implementation note: this criterion requires access to the model’s internal states layer by layer. It is not available when using models through APIs such as OpenAI, Anthropic, or Google. A realistic prototype would use local models such as Llama 3 or Mistral, or approximate stability through the variance of embeddings generated from multiple paraphrases of the same concept.

2.4 Structural Bridges: Transferring Knowledge Across Domains

If two memory regions have similar geometric structure, validated knowledge from one can be transferred to the other without having to re-establish it from scratch. A bridge is an orthogonal transformation T that maps region A onto region B while preserving distances and angles.

The bridge is constructed using orthogonal Procrustes analysis. Given corresponding nodes $\{a_i\} \subset A$ and $\{b_i\} \subset B$:

Centering:

$$\tilde{a}_i = a_i - \bar{a}, \tilde{b}_i = b_i - \bar{b}$$

Cross-covariance:

$$C = \sum_i \tilde{b}_i \tilde{a}_i^T$$

SVD:

$$C = U \Sigma V^T$$

Optimal transformation:

$$T = UV^T$$

The quality of the bridge is measured by the normalized residual error after Procrustes alignment. A perfect bridge has an error close to 0. A weak bridge has an error greater than 0.3, making knowledge transfer risky.

Bridges can be composed: if a bridge exists from A to B and another from B to C, their composition becomes a candidate bridge from A to C, generated without searching for it directly. This creates controlled generative power.

2.5 Spectral Clustering: Domains Emerge Rather Than Being Defined

Knowledge domains are not defined in advance. They emerge as high-density regions with low-density boundaries—clusters in embedding space. The algorithm is the spectral decomposition of the graph Laplacian:

Similarity matrix:

$$W_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{2\varepsilon^2}\right)$$

Laplacian:

$$L = D - W \text{ where } D_{ii} = \sum_j W_{ij}$$

Decomposition:

$$L = \Phi \Lambda \Phi^T$$

Clustering is performed on the first *keigenvectors*, using the Fiedler spectral gap.

Domains may emerge as new clusters, merge when a unifying principle is discovered, split when a category is too coarse, or drift gradually. When domains change, bridges remain because they are defined between geometric regions rather than labels. Geometry is more stable than ontology.

2.6 The Three Memory Levels: The Gate to Operational Reality

Level	Function	Admission criterion	Decay
Active memory	Operational reasoning. Everything the LLM uses to formulate a response.	Stability > 0.9 + explicit anchor + multiple validation	Slow, claim-type-specific
Episodic memory	Hypotheses under exploration. Plausible but unconfirmed.	Stability > 0.7 OR partial anchor	Fast; decays without reinforcement
Cold storage	Systematic errors and confabulation patterns. Never used for reasoning.	Confidence < 0.1	None; retained for calibration

The invariant is the *conditio sine qua non*: no node can exist in active memory without an explicit anchor to a real source. Confabulation is not fought after the fact; it is made structurally impossible because fantasy has no pathway into active memory. It may exist in episodic memory, where it naturally decays.

Cold storage is not a trash bin. Failed transformations—namely, bridges that did not hold—and rejected hypotheses define regions of structural incompatibility: areas where domains are genuinely heterogeneous. This is negative knowledge: it indicates where not to search.

3. Critical Analysis: Advantages, Limitations, and Conditions

3.1 Advantages

Confabulation is structurally impossible in active memory

The goal is not merely to reduce hallucinations, but to make them impossible by construction within operational memory. A conventional RAG system filters after retrieval; CM-LLM excludes before admission. The difference is not one of degree, but of mechanism.

Automatic epistemic hygiene

Differential decay by claim type has a valuable side effect: content extracted from low-quality sources like social media, aggregators, and substance-free viral content does not receive reinforcement from authoritative sources. Without reinforcement, it decays.

The system does not need to know in advance that a source is poor; it infers this from the absence of independent confirmation over time. The knowledge that survives is knowledge confirmed from multiple directions.

Transparency and traceability

Every statement in active memory carries an explicit anchor. “Where does this statement come from?” always has a verifiable answer. This is essential in professional contexts—legal, medical, and compliance-related—in which source accountability is not optional.

Evolution over time without catastrophic forgetting

The system accumulates knowledge incrementally. The three-level structure naturally manages the tension between remembering—stable active memory—and forgetting—episodic memory that decays. There is no need to choose between the two; they occur appropriately according to the type of information.

Measurable cross-domain discovery

Structural bridges based on Procrustes analysis create connections between domains with an intrinsic quality measure. The system does not merely claim that it has “found an interesting connection,” which is difficult to verify. Instead, it can state that “the structure of domain A is isomorphic to the structure of domain B with an error of 0.12,” which is verifiable and falsifiable.

3.2 Limitations

Access to the model’s internal states

The exact form of the Cauchy-inspired stability criterion requires intermediate embeddings from every layer. This information is unavailable when using APIs from OpenAI, Anthropic, or Google. A realistic prototype would therefore use local open-source models. This deployment constraint also brings other advantages, including privacy, lower costs, and greater control.

Internal consistency is not validation

A system can be internally consistent and still be false.

Structural bridges are internally falsifiable: an isomorphism either holds or it does not. However, for empirical and interpretive claims, consistency alone is insufficient. The validator-regress problem or the longstanding question of who validates the validator cannot be fully resolved internally.

Periodic human grounding is therefore structurally necessary, not optional. The manual kill switch is the boundary condition that closes the regress, not an emergency backdoor.

Computational cost

Batch decay performed every 24 hours and spectral reclustering performed weekly are computationally manageable at professional scale. Stability calculation is $O(L^2)$ for a sequence of L layers, although early stopping can mitigate this cost.

Pairwise Procrustes analysis across all domain pairs scales quadratically with the number of domains. On very large knowledge bases, sampling is therefore required.

Bridges transfer analogy, not radical novelty

A system that generates knowledge solely through structural transfer between known domains can produce sophisticated insights, but not genuine invention. It can discover that two things resemble one another, but it cannot create something genuinely orthogonal to everything that already exists.

This tension remains unresolved and keeps humans central.

A high flow of external reality is required

The system works as long as it receives fresh input from real sources. Deprived of new external reality, it drifts toward self-reference: it validates new hypotheses against earlier hypotheses that were themselves not fully validated, and reality progressively loses weight.

The operational consequence is that CM-LLM is highly effective for actively maintained domains but becomes dead weight for static and isolated knowledge bases.

3.3 What Is Genuinely New and What Is Not

The individual components already exist separately: distributional embeddings, temporal decay, Procrustes alignment of spaces, spectral clustering, and memory-generator architectures. The novelty lies not in the building blocks, but in their synthesis and in three specific framings:

- Decay as claim-type-specific metric deformation, rather than as an arbitrary uniform TTL.
- Cold storage as meta-learning data about the system's own confabulation bias, rather than as an inert trash bin.

- Creativity as anchored structural transfer through measurable bridges, rather than as unconstrained free-form generation.

4. Roadmap Toward a Falsifiable Prototype

PHASE 1: MINIMAL FALSIFICATION EXPERIMENT: 2–4 WEEKS

Select two domains with a structural isomorphism established in the literature for example, classical mechanics and thermodynamics, or economics and population ecology.

Construct embeddings from a Wikipedia corpus and perform Procrustes alignment. Measure whether the structure transfers meaningfully. If Procrustes fails to produce significant alignments in domains where the isomorphism is established, the core idea that “structure transfers” does not hold for those data, and this can be discovered within weeks rather than years.

PHASE 2: PROTOTYPE WITH STRUCTURED MEMORY: 4–6 WEEKS

- Implement a Gaussian embedding space with $d = 768$ using a local model.
- Implement the three memory levels with explicit transitions.
- Implement claim-type-specific decay.
- Test the system on a real professional corpus of 100–500 documents.

PHASE 3: BRIDGES AND EMERGENT DOMAINS: 4–6 ADDITIONAL WEEKS

- Add Procrustes-based bridge discovery.
- Add spectral clustering for emergent domains.
- Benchmark the system against conventional RAG using confabulation and traceability metrics.

This document is a technical proposal in the form of an open contribution. The architecture is theoretically coherent; its promise depends on moving toward implementation, beginning with Phase 1, where the system can fail quickly enough to generate useful learning.

CM-LLM

Cognitive Memory-Augmented Large Language Models

Specifica tecnica — bozza di contributo libero

Abstract

I Large Language Model soffrono di tre limiti strutturali correlati: sono **stateless** (ogni sessione ricomincia da zero), tendono alla **confabulazione** (generano affermazioni plausibili ma non ancorate), e trattano ogni informazione con lo stesso peso indipendentemente dalla sua età e tipo. Proponiamo **CM-LLM**, un'architettura che risolve tutti e tre non modificando il transformer di base, ma incapsulandolo in un sistema di memoria cognitiva strutturata.

Il claim centrale: la confabulazione è strutturalmente impossibile nella memoria operativa, non per filtraggio a posteriori ma per costruzione ontologica.

Ogni nodo in memoria attiva porta un'ancora esplicita a una fonte reale; senza di essa, non può esistere lì. La conoscenza non viene filtrata dopo che è entrata e non entra se non è ancorata.

Un beneficio emergente è il meccanismo di **decadimento per tipo di claim necessario** per gestire l'obsolescenza della conoscenza e funge anche da **igiene epistemica automatica**. Contenuti superficiali, rumorosi o privi di rinforzo (tipicamente quelli estratti da fonti di bassa qualità) decadono e scompaiono dalla memoria operativa senza intervento manuale. Il sistema tende naturalmente a trattenere ciò che è stato più volte confermato da fonti diverse e a dimenticare il resto.

1. Il problema che CM-LLM risolve

1.1 Tre limiti, una radice comune

Gli LLM moderni sono fondamentalmente macchine di compressione statistica addestrate una volta e congelate. Questa è la loro forza (generalizzazione) e il loro limite strutturale:

- **Statelessness:** ogni query ricomincia da zero. Il modello non ricorda cosa ha detto ieri, né che il dato di mercato che sta citando era corretto nel 2022 e non lo è più.
- **Confabulazione:** il modello non distingue internamente "questo l'ho letto in una fonte affidabile" da "questo mi sembra plausibile". Il risultato è che presenta entrambi con la stessa sicurezza.
- **Peso uniforme:** un articolo scientifico peer-reviewed e un post su X hanno lo stesso peso nel momento in cui entrano nel contesto. Non esiste il concetto di decay: un'informazione non perde rilevanza nel tempo.

Questi tre limiti hanno una radice comune: il transformer non ha una rappresentazione interna dello statuto epistemico della conoscenza. SA quello che sa, ma non SA quanto ci può contare, da dove viene, o da quanto tempo è valido.

1.2 Il decay come igiene, non solo come cronologia

Una conseguenza non ovvia del decadimento differenziale: i contenuti estratti da fonti di bassa qualità (social media, siti aggregatori, contenuti privi di sostanza) hanno **nessun meccanismo di rinforzo**. Una notizia virale su X non viene citata in paper scientifici, non appare in documenti tecnici, non si collega ad altri nodi validati. Senza rinforzo, decade. Una definizione matematica invece viene citata ogni volta che si usa quel concetto: riceve rinforzo costante e rimane.

Il sistema non ha bisogno di distinguere manualmente "buona fonte" da "cattiva fonte". Lo fa implicitamente: la conoscenza che sopravvive è quella che riceve conferma da più direzioni nel tempo. Il rumore si auto-elimina.

2. Architettura: cinque meccanismi, un sistema

CM-LLM non introduce nuovi modelli di machine learning. Usa tecnologie esistenti come embedding, algebra lineare, clustering tutte assemblate in modo che le loro proprietà si rinforzino a vicenda. I cinque meccanismi sono visti diversi dello stesso oggetto, non moduli separati.

2.1 Embedding distribuzionale: l'incertezza nella geometria

Ogni concetto non è rappresentato come un punto fisso nello spazio dei significati, ma come una distribuzione gaussiana:

$$\text{concetto} \rightarrow \mathcal{N}(\mu, \Sigma) \quad \text{dove } \mu \in \mathbb{R}^d, \Sigma \in \mathbb{R}^{d \times d}$$

μ è il centro della distribuzione (il significato prototipico). Σ è la covarianza (l'incertezza semantica). La **confidenza** è la concentrazione della distribuzione:

$$\text{confidenza} = 1 / \sqrt{\det(\Sigma)}$$

Σ piccola $\rightarrow$ distribuzione concentrata $\rightarrow$ alta confidenza. Σ grande $\rightarrow$ distribuzione diffusa $\rightarrow$ incertezza. Il vantaggio rispetto a un punto fisso è che l'incertezza è codificata nella geometria stessa, non come metadato separato. Due concetti possono essere "vicini" e diffusi (vicinanza incerta) o vicini e concentrati (vicinanza solida): distinzione che un embedding puntuale non sa fare.

2.2 Decadimento per tipo di claim: la metrica si deforma nel tempo

Il decadimento non è un timer fisso (TTL). È una deformazione geometrica dello spazio: senza rinforzo, la distribuzione di un concetto si allarga, diventa meno precisa. Il concetto non scompare ma diventa sempre più incerto finché non viene archiviato.

Il coefficiente di decadimento α dipende dal tipo di claim, non dalla fonte:

Tipo di claim	α (decadimento/giorno)	Tempo di dimezzamento
Dati di mercato, prezzi, notizie	0.10	≈ 1 settimana
Opinioni, interpretazioni, analisi	0.05	≈ 3 mesi
Fatti scientifici consolidati	0.001	≈ 5 anni
Definizioni matematiche	0.0001	≈ 50 anni

La formula di aggiornamento della covarianza a ogni passo temporale Δt :

$$\Sigma(t + \Delta t) = \Sigma(t) + \alpha^T \cdot \Delta t \cdot I^d$$

La confidenza decade esponenzialmente: $\text{confidenza}(t) \propto e^{(-\lambda^T t)}$. Quando scende sotto soglia 0.1, il nodo viene spostato in archivio freddo.

2.3 Criterio di stabilità Cauchy-inspired: quando una rappresentazione è "matura"

Un'idea è matura quando il modo in cui il modello la rappresenta non cambia più mentre elabora livelli successivi. Formalmente: si misura quanto la rappresentazione di un concetto converge attraverso i layer dell'LLM.

Per una sequenza di rappresentazioni $h_1, h_2, \dots, h_l$ attraverso L layer:

$$\text{stabilità}(h_{1:l}) = [1/C(L, 2)] \cdot \sum_{i < j} \exp(-\|h_i - h_j\|^2 / 2\sigma^2)$$

Stabilità ≈ 1 : la successione è quasi-Cauchy (tutti gli embedding vicini tra loro) — la rappresentazione è **matura**. Stabilità ≈ 0 : la rappresentazione è instabile — il concetto non si è ancora "assestato" nei layer del modello.

Questo segnale serve a due cose: come criterio di ammissione alla memoria attiva (solo rappresentazioni stabili entrano) e come early stopping nell'inferenza (se la stabilità supera soglia prima dell'ultimo layer, si può fermare prima).

Nota implementativa: questo criterio richiede accesso agli stati interni del modello layer per layer. Con modelli via API (OpenAI, Anthropic) non è disponibile. Il prototipo realistico usa modelli locali (Llama 3, Mistral) o approssima la stabilità con varianza degli embedding su paraphrase multiple dello stesso concetto.

2.4 Ponti strutturali: trasferimento di conoscenza tra domini

Se due regioni della memoria hanno struttura geometrica simile, la conoscenza validata in una può trasferirsi all'altra senza ridimostrarla. Un ponte è una trasformazione ortogonale T che mappa la regione A nella regione B preservando distanze e angoli.

Costruzione con analisi di Procrustes ortogonale: dati nodi corrispondenti $\{a_i\} \subset A$ e $\{b_i\} \subset B$,

1. Centra: $\tilde{a} = a_i - \bar{a}$, $\tilde{b} = b_i - \bar{b}$
2. Covarianza incrociata: $C = \sum_i \tilde{b}_i \tilde{a}_i^T$
3. SVD: $C = U \Sigma V^T$
4. Trasformazione ottimale: $T = UV^T$ (matrice ortogonale)

La qualità del ponte si misura come errore residuo normalizzato dopo il Procrustes. Ponte perfetto $\rightarrow$ errore ≈ 0 . Ponte debole $\rightarrow$ errore > 0.3 , trasferimento rischioso.

I ponti si compongono: se esiste un ponte $A \rightarrow B$ e uno $B \rightarrow C$, la loro composizione è un candidato ponte $A \rightarrow C$, generato senza cercarlo direttamente. Potenza generativa controllata.

2.5 Clustering spettrale: i domini emergono, non vengono definiti

I domini di conoscenza non vengono definiti a priori. Emergono come regioni di alta densità con bassa densità ai confini — cluster nello spazio di embedding. L'algoritmo è la decomposizione spettrale del Laplaciano del grafo:

1. Matrice di similarità: $W_{ij} = \exp(-\|x_i - x_j\|^2 / 2\sigma^2)$
2. Laplaciano: $L = D - W$ (dove $D_{ii} = \sum_j W_{ij}$)
3. Decomposizione: $L = \Phi \Lambda \Phi^T$
4. Clustering sui primi k autovettori (gap spettrale di Fiedler)

I domini possono nascere (nuovo cluster), fondersi (principio unificante scoperto), dividersi (categoria troppo grossolana), o derivare lentamente. Quando i domini cambiano, i ponti restano — sono definiti tra regioni geometriche, non tra etichette. La geometria è più stabile dell'ontologia.

2.6 I tre livelli di memoria: il cancello verso la realtà operativa

Livello	Funzione	Criterio di ingresso	Decadimento
Memoria attiva	Ragionamento operativo. Tutto ciò che l'LLM usa per rispondere.	Stabilità > 0.9 + ancora esplicita + validazione multipla	Lento, per tipo di claim
Memoria episodica	Ipotesi in esplorazione.	Stabilità > 0.7 OR ancora parziale	Veloce, decade senza rinforzo

	Plausibile ma non confermato.		
Archivio freddo	Errori sistematici, pattern di confabulazione. Mai usato per ragionare.	Confidenza < 0.1	Nulla. Conservato per calibrazione.

L'invariante è la conditio sine qua non: nessun nodo può esistere in memoria attiva senza un'ancora esplicita a una fonte reale. La confabulazione non viene combattuta a posteriori ma è resa strutturalmente impossibile perché la fantasia non ha un percorso per entrare in memoria attiva. Può esistere in memoria episodica, dove decade naturalmente.

L'archivio freddo non è un cestino. Le trasformazioni fallite cioè quelle con ponti che non hanno retto, ipotesi scartate definiscono le zone di incompatibilità strutturale: regioni dove i domini sono genuinamente eterogenei. È conoscenza negativa, dice dove non cercare.

3. Analisi critica: vantaggi, limiti, condizioni

3.1 Vantaggi

Confabulazione strutturalmente impossibile nella memoria attiva

Non si tratta di ridurre le allucinazioni ma si tratta di renderle impossibili per costruzione nella memoria operativa. Un sistema RAG filtra dopo; CM-LLM esclude prima. La differenza non è di grado, è di meccanismo.

Igiene epistemica automatica

Il decay differenziale per tipo di claim ha un effetto collaterale prezioso: i contenuti estratti da fonti di bassa qualità (social media, aggregatori, contenuti virali privi di sostanza) non ricevono rinforzo da fonti autorevoli. Senza rinforzo, decadono. Il sistema non deve sapere a priori che una fonte è scarsa ma lo inferisce dall'assenza di conferma indipendente nel tempo. La conoscenza che sopravvive è quella confermata da più direzioni.

Trasparenza e tracciabilità

Ogni affermazione in memoria attiva porta un'ancora esplicita. "Da dove viene questa affermazione?" ha sempre una risposta verificabile. Questo è essenziale per contesti professionali (legale, medico, compliance) dove la responsabilità della fonte non è opzionale.

Evoluzione nel tempo senza catastrophic forgetting

Il sistema accumula conoscenza incrementalmente. La struttura a tre livelli gestisce naturalmente la tensione tra ricordare (memoria attiva stabile) e dimenticare (episodica che decade): non serve scegliere tra i due, avvengono in modo appropriato per tipo di informazione.

Scoperta cross-dominio misurabile

I ponti strutturali via Procrustes producono connessioni tra domini con una misura di qualità intrinseca. Non è "il sistema ha trovato una connessione interessante" (non verificabile) — è "la struttura del dominio A è isomorfa alla struttura del dominio B con errore 0.12" (verificabile e falsificabile).

3.2 Limiti

Accesso agli stati interni del modello

Il criterio di stabilità Cauchy-inspired, nella forma esatta, richiede gli embedding intermedi layer per layer. Con modelli via API (OpenAI, Anthropic, Google) questo non è disponibile. Il prototipo realistico usa modelli locali open-source. Questo è un vincolo di deployment che spinge verso l'esecuzione locale, che ha altri vantaggi (privacy, costi, controllo).

La coerenza interna non è validazione

Un sistema internamente consistente può essere internamente consistente e falso.

I ponti strutturali sono falsificabili internamente (un isomorfismo regge o non regge), ma per i claim empirici e interpretativi la coerenza non basta. Il regresso del validatore cioè l'annosa questione di chi valida il validatore non ha chiusura interna completa. Il grounding umano periodico è strutturalmente necessario, non opzionale. Il killer switch manuale è la condizione al contorno che chiude il regresso, non una backdoor di emergenza.

Costo computazionale

Il decadimento batch (ogni 24h) e il ri-clustering spettrale (settimanale) sono computazionalmente trattabili su dimensioni professionali. Il calcolo della stabilità è $O(L^2)$ per sequenza di L layer ma mitigabile con early stopping. Il Procrustes pairwise tra tutte le coppie di domini scala quadraticamente nel numero di domini: su basi molto grandi richiede campionamento.

I ponti trasferiscono analogia, non novità radicale

Un sistema che genera conoscenza solo per trasferimento strutturale tra domini noti è capace di insight sofisticati ma non di vera invenzione di scoprire che due cose si assomigliano, non di creare qualcosa genuinamente ortogonale a tutto ciò che esiste.

Questa tensione rimane non risolta e rende l'umano centrale.

Flusso alto di realtà esterna necessario

Il sistema funziona finché riceve input freschi da fonti reali. Privato di nuova realtà esterna, deriva verso l'autoreferenzialità: valida nuove ipotesi contro ipotesi precedenti anch'esse non completamente validate, la realtà perde peso progressivamente. La conseguenza operativa: CM-LLM è eccellente per domini attivamente alimentati, diventa peso morto per basi statiche e isolate.

3.3 Cosa è genuinamente nuovo (e cosa non lo è)

I singoli componenti esistono separatamente: embedding distribuzionali, decadimento temporale, Procrustes per allineamento di spazi, clustering spettrale, architetture memoria-generatore. La novità non è nei mattoni, è nella sintesi e in tre framing specifici:

- Il decadimento come deformazione della metrica per tipo di claim (non come TTL arbitrario uniforme).
- L'archivio freddo come dato di meta-apprendimento sul proprio bias di confabulazione (non come cestino inerte).
- La creatività come trasferimento strutturale ancorato attraverso ponti misurabili (non come generazione libera non vincolata).

4. Roadmap verso un prototipo falsificabile

Fase 1: Esperimento falsificante minimo (2–4 settimane)

Prendere due domini con isomorfismo strutturale noto dalla letteratura (es. meccanica classica / termodinamica, o economia / ecologia delle popolazioni). Costruire embedding su un corpus Wikipedia. Eseguire Procrustes. Misurare se la struttura si trasferisce in modo sensato. Se il Procrustes non produce allineamenti significativi su domini dove l'isomorfismo è stabilito, l'idea-madre "la struttura si trasferisce" non regge su quei dati e lo si scopre in settimane, non anni.

Fase 2 Prototipo con memoria strutturata (4–6 settimane)

- Implementare spazio di embedding gaussiano ($d = 768$, modello locale)
- Implementare i tre livelli di memoria con transizioni esplicite
- Implementare decadimento differenziale per tipo di claim
- Testare su corpus professionale reale (100–500 documenti)

Fase 3 Ponti e domini emergenti (4–6 settimane aggiuntive)

- Aggiungere Procrustes per scoperta di ponti
- Aggiungere clustering spettrale per domini
- Benchmark contro RAG classico su metriche di confabulazione e tracciabilità

Questo documento è una proposta tecnica in forma di contributo libero. L'architettura è teoricamente coerente; la sua promessa è contingente a una discesa nell'implementazione che parte dalla Fase 1 dove si può fallire in fretta abbastanza da imparare.